



暨南大學
JINAN UNIVERSITY



多元统计分析及R语言建模

第5章 广义与一般线性模型及R使用

王斌会 教授



●基本内容：

数据的分类与模型选择、广义线性模型概述、Logistic回归模型、对数线性模型、一般线性模型的计算。

●基本要求：

要求学生针对因变量和解释变量的取值性质，了解统计模型的类型。掌握数据的分类与模型选择方法，并对广义线性模型和一般线性模型有初步的了解。



1. 变量的取值类型:

因变量 $y \in \left\{ \begin{array}{l} \text{连续变量} \\ \text{"0-1"变量或称二分类变量} \\ \text{有序变量(等级变量)} \\ \text{多分类变量} \\ \text{连续伴有删失变量} \end{array} \right.$

解释变量 $x \in \left\{ \begin{array}{l} \text{连续变量} \\ \text{分类变量} \\ \text{等级变量} \end{array} \right.$



2.模型选择方式：基本公式

$$\begin{cases} Y = X\beta + e \\ E(e) = 0, cov(e) = \sigma^2 I \end{cases}$$

<div><div>y</div><div>X</div></div>	连续变量	0-1变量	有序变量	多分类变量	连续伴有删失
连续变量	线性回归方程	logistic回归模型	累积比数模型 对数线性模型	对数线性模型 多分类logistic回归模型	cox比例风险模型
分类变量	实验设计模型（方差分析模型）				
连续变量 分类变量	协方差分析模型				



在广义线性模型中，均假定观察值 y 具有指数族概率密度函数

$$f(y|\theta, \phi) = \exp\{[y\theta - b(\theta)]/a(\phi) + c(y, \phi)\}$$

其中 $a(\cdot)$ 、 $b(\cdot)$ 和 $c(\cdot)$ 是三种函数形式， θ 为典则参数。

表5.1 广义线性模型中的常用分布族

分布	函数	模型
正态 (Gaussian)	$E(y) = X'\beta$	普通线性模型
二项 (Binomial)	$E(y) = \frac{\exp(X'\beta)}{1+\exp(X'\beta)}$	Logistic 模型和概率模型单位 (probit) 模型
泊松 (Poisson)	$E(y) = \exp(X'\beta)$	对数线性模型



在广义线性模型中，(5.4) 式中的典则参数不仅仅是 μ 的函数，还是参数 $\beta_0, \beta_1, \dots, \beta_p$ 的线性表达式。对 μ 作变换，则可得到这三种分布连接函数的形式

正态分布: $m(\mu) = \mu = \sum \beta_j x_j$

二项分布: $m(\mu) = \log\left(\frac{\mu}{1-\mu}\right) = \sum \beta_j x_j$

Poisson 分布: $m(\mu) = \log(\mu) = \sum \beta_j x_j$

广义线性模型函数 `glm()` 的用法

`glm(formula, family = gaussian, data,...)`

`formula` 为公式，即为要拟合的模型

`family` 为分布族，包括正态分布 (`gaussian`)、二项分布 (`binomial`)、泊松分布 (`poisson`) 和伽玛分布 (`gamma`)，分布族还可以通过选项 `link=` 来指定使用的连接函数

`data` 为可选择的数据框。



● 说明：

2、**Logistic模型**：函数形式

$$\text{logit}(y) = \ln \frac{P}{1-P} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p = X\beta$$

其中参数估计采用极大似然估计。

● 举例：

对45名驾驶员的调查结果，其中四个变量的含义为：

x_1 ：表示视力状况，它是一个分类变量，1表示好，0表示有问题；

x_2 ：年龄，数值型；

x_3 ：驾车教育，它也是一个分类变量，1表示参加过驾车教育，0表示没有；

y ：分类变量（去年是否出过事故，1表示出过事故，0表示没有）。



(1) 建立全变量logistic回归模型:

```
d5.1=read.table("clipboard",header=T) #读取例5.1数据
logit.glm<-glm(y~x1+x2+x3,family=binomial,data=d5.1) #Logistic回归模型
summary(logit.glm) #Logistic回归模型结果
```

```
Call:
glm(formula = y ~ x1 + x2 + x3, family = binomial, data = d5.1)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.5636  -0.9131  -0.7892   0.9637   1.6000

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  0.597610   0.894831   0.668   0.5042
x1          -1.496084   0.704861  -2.123   0.0338 *
x2           -0.001595   0.016758  -0.095   0.9242
x3           0.315865   0.701093   0.451   0.6523
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 62.183  on 44  degrees of freedom
Residual deviance: 57.026  on 41  degrees of freedom
AIC: 65.026

Number of Fisher Scoring iterations: 4
```

得到初步的logistic回归模型:

$$p = \frac{\exp(0.5976 - 1.4961x_1 - 0.0016x_2 + 0.3159x_3)}{1 + \exp(0.5976 - 1.4961x_1 - 0.0016x_2 + 0.3159x_3)}$$

(2) 逐步筛选变量logistic回归模型:

```
logit.step<-step(logit.glm,direction="both")
#逐步筛选法变量选择
```

```
Start:  AIC=65.03
y ~ x1 + x2 + x3

      Df Deviance   AIC
- x2    1   57.035 63.035
- x3    1   57.232 63.232
<none>   1   57.026 65.026
- x1    1   61.936 67.936

Step:  AIC=63.03
y ~ x1 + x3

      Df Deviance   AIC
- x3    1   57.241 61.241
<none>   1   57.035 63.035
+ x2    1   57.026 65.026
- x1    1   61.991 65.991

Step:  AIC=61.24
y ~ x1

      Df Deviance   AIC
<none>   1   57.241 61.241
+ x3    1   57.035 63.035
+ x2    1   57.232 63.232
- x1    1   62.183 64.183
```

```
summary(logit.step)
#逐步筛选法变量选择结果
```

```
Call:
glm(formula = y ~ x1, family = binomial, data = d5.1)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.4490  -0.8782  -0.8782   0.9282   1.5096

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)   0.6190    0.4688   1.320   0.1867
x1           -1.3728    0.6353  -2.161   0.0307 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 62.183  on 44  degrees of freedom
Residual deviance: 57.241  on 43  degrees of freedom
AIC: 61.241

Number of Fisher Scoring iterations: 4
```

由此得到新的logistic回归模型:

$$p = \frac{\exp(0.6190 - 1.3728x_1)}{1 + \exp(0.6190 - 1.3728x_1)}$$



(3) : 预测发生交通事故的概率

```
pre1<-predict(logit.step,data.frame(x1=1)) #预测视力正常司机Logistic回归结果
p1<-exp(pre1)/(1+exp(pre1)) #预测视力正常司机发生事故概率
pre2<-predict(logit.step,data.frame(x1=0)) #预测视力有问题的司机Logistic回归结果
p2<-exp(pre2)/(1+exp(pre2)) #预测视力有问题的司机发生事故概率
c(p1,p2) #结果显示
```

```
      1      1
0.32  0.65
```


● 说明：

3、对数线性模型：函数形式 $\ln(m_{ij}) = \alpha_i + \beta_j + \varepsilon_{ij}$ $\ln(m_{ij}) = \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ij}$

式2含有交叉效应

● 举例：

某企业想了解顾客对其产品是否满意，同时还想了解不同收入的人群对其产品的满意程度是否相同。

	满意	不满意	合计
高	53	38	91
中	434	108	542
低	111	48	159
合计	598	194	792

y	x1	x2
53	1	1
434	2	1
111	3	1
38	1	2
108	2	2
48	3	2

数据形式变为：用y表示频数，x1表示收入人群，x2表示满意程度



(1) 建立Poisson对数线性模型:

```
Call:
glm(formula = y ~ x1 + x2, family = poisson(link = log), data = d5.2)

Deviance Residuals:
    1      2      3      4      5      6 
-10.784  14.444  -8.468  -2.620   4.960  -3.142 

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   6.15687    0.14196  43.371  < 2e-16 ***
x1             0.12915    0.04370   2.955  0.00312 **
x2            -1.12573    0.08262 -13.625  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 662.84  on 5  degrees of freedom
Residual deviance: 437.97  on 3  degrees of freedom
AIC: 481.96

Number of Fisher Scoring iterations: 5
```

从检验结果可看出， $p_1=0.0031<0.01$ ， $p_2<0.01$ ，说明收入和满意程度对产品有重要影响



● 说明：

1、完全随机设计模型：函数形式 $y_{ij} = \mu + \alpha_i + e_{ij} \quad i = 1, 2, \dots, G \quad j = 1, 2, \dots, n_i$
其中 μ 表示观察结果 y_{ij} 的总体均值， α_i 是哑变量的系数，称为A因素各水平的主效应， e_{ij} 是误差项。

● 举例：

设有3台机器，用来生产规格相同的铝合金薄板。现从3台机器生产出的薄板中各随机抽取5块，测出厚度值，见下表，试分析各机器生产的薄板厚度有无显著差异？

机器1	2.36	2.38	2.48	2.45	2.47	2.43
机器2	2.57	2.53	2.55	2.54	2.56	2.61
机器3	2.58	2.64	2.59	2.67	2.66	2.62



```
d5.3=read.table("clipboard",header=T) #读取例5.3数据
anova(lm(Y~factor(A),data=d5.3)) #完全随机设计模型方差分析
```

(1) 数据格式为:

```
Y A
2.36 1
2.38 1
2.48 1
2.45 1
2.47 1
2.43 1
2.57 2
2.53 2
2.55 2
2.54 2
2.56 2
2.61 2
2.58 3
2.64 3
2.59 3
2.67 3
2.66 3
2.62 3
```

Analysis of Variance Table

Response: Y

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
factor(A)	2	0.122233	0.061117	40.534	8.94e-07 ***
Residuals	15	0.022617	0.001508		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

P<0.05，说明各机器生产的薄板厚度有显著差异。



● 说明：

2、随机单位组设计模型：函数形式 $y_{ij} = \mu + \alpha_i + \beta_j + e_{ij} \quad i = 1, 2, \dots, G \quad j = 1, 2, \dots, n$
其中 μ 为总均数， α_i 为处理因素A的第*i*个水平的效应； β_j 为第*j*个单位组的效应， e_{ij} 为误差项。

● 举例：

使用4种燃料，3种推进器作火箭射程试验，每一种组合情况做一次试验，则得火箭射程列在下表中，试分析各种燃料A与各种推进器B对火箭射程有无显著影响？

BA	A1	A2	A3	A4
B1	582	491	601	758
B2	562	541	709	582
B3	653	516	392	487



```
d5.4=read.table("clipboard",header=T) #读取例5.4数据
anova(lm(Y~factor(A)+factor(B),data=d5.4)) #随机单位组设计模型方差分析
```

(1) 数据格式为:

Y	A	B
582	1	1
491	2	1
601	3	1
758	4	1
562	1	2
541	2	2
709	3	2
582	4	2
653	1	3
516	2	3
392	3	3
487	4	3

Analysis of Variance Table						
Response: Y						
	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
factor(A)	3	15759	5253	0.4306	0.7387	
factor(B)	2	22385	11192	0.9174	0.4491	
Residuals	6	73198	12200			

PA>0.05，说明各种燃料A对火箭射程有无显著影响，
PB>0.05，说明各种推进器B对火箭射程也无显著影响。



5 广义与一般线性模型及R使用 \Rightarrow 案例分析 广义线性模型及其应用

关于40个不同年龄（age，定量变量）和性别（sex，定性变量，用0和1代表女和男）的人对某项服务产品的观点（y，二水平定性变量，用1和0代表认可与不认可）的数据。

一、数据管理

二、R语言操作

拟合的模型为：

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x \quad \text{或者等价地} \quad p = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

```
Case4=read.table("clipboard",header=T);Case4
fm=glm(y~sex+age,family=binomial,data=Case4)
fm
summary(fm)
attach(Case4)
Pr=predict(fm,data.frame(list(sex,age))) #模型预测
p=exp(Pr)/(1+exp(Pr))
cbind(sex,age,y,p)
plot(age,Pr)
detach(Case4)
```



谢谢！